📌 Lições Aprendidas – Qualidade de Dados na Camada Bronze

Contexto do Projeto

Este projeto implementa uma arquitetura **Medallion (Bronze / Silver / Gold)** para análise de fluxo de caixa, utilizando **Supabase (PostgreSQL)** como banco de dados e **Power BI** para visualização.

Durante a validação do indicador **Saldo Operacional**, foi identificada uma divergência relevante entre: - 📊 Resultado esperado (fonte Excel): **-5,88 milhões** - 📉 Resultado calculado no Data Warehouse: **-4,03 milhões**

Essa diferença motivou uma análise detalhada de qualidade de dados ao longo das camadas.

Problema Identificado

Após diversos checks por camada (Bronze → Silver → Gold), foi constatado que:

- A **tabela bronze.movimentos_raw** foi populada a partir de um **upload manual de Excel** no Supabase.
- A coluna `valor`, originalmente monetária, foi carregada como **TEXT**, contendo:
  - separador de milhar (`.`)
  - separador decimal brasileiro (`,`)
  - símbolos e formatações visuais do Excel

Durante o upload, parte dos valores **foi interpretada incorretamente**, resultando em: - perda silenciosa de dados numéricos - soma incorreta já na camada Bronze

📌 Evidência crítica:

```sql
select sum(
  cast(
    replace(
      replace(valor, '.', ''),
    ',', '.') as numeric(14,2)
  )
) from bronze.movimentos_raw;
```

Resultado divergente em relação ao Excel original.

Impacto no Pipeline

Como a arquitetura Medallion é **cumulativa**, o erro na Bronze propagou-se para:

- Silver (transformações corretas, porém baseadas em dado incorreto)
- Gold (fatos e métricas inconsistentes)
- Power BI (indicador financeiro errado)

🔴 Importante: **nenhuma transformação posterior conseguiu recuperar valores perdidos na ingestão**.

Decisão Técnica

Foi adotada a decisão correta do ponto de vista de engenharia de dados:

- ❌ Não corrigir valores manualmente nas camadas Silver ou Gold
- ❌ Não "ajustar" métricas no Power BI
- ✅ **Reprocessar a ingestão desde a origem**

A tabela Bronze foi descartada e o arquivo foi reingerido corretamente.

Solução Aplicada

1. Exclusão da tabela Bronze:

```
drop table bronze.movimentos_raw;
```

2. Preparação correta do arquivo fonte:

- Conversão para **CSV UTF-8**
- Remoção de:
  - separador de milhar
  - símbolos monetários
- Padronização do decimal para `.`

3. Novo upload no Supabase

4. Validação imediata pós-ingestão:

```
select count(*) from bronze.movimentos_raw;
select sum(valor::numeric) from bronze.movimentos_raw;
```

5. Continuidade do pipeline somente após validação positiva

Lição Aprendida (Principal)

> **A camada Bronze é sagrada. Se o dado entra errado nela, todo o pipeline estará errado.**

Especialmente quando a fonte é: - Excel - upload manual - dados financeiros - localidade PT-BR

🚨 **Nunca confiar em dados ingeridos sem validação numérica imediata.**

Boas Práticas Consolidadas

- Bronze deve ser tratada como **imutável**
- Qualquer erro → **reingestão**, não correção
- Sempre executar checks mínimos:
  - contagem de linhas
  - soma de valores
  - validação de nulos
- Excel deve ser considerado **fonte não confiável para números** sem pré-processamento

---

Valor Profissional do Caso

Este episódio demonstrou competências fundamentais de Engenharia de Dados:

- investigação por camadas
- validação quantitativa
- rastreabilidade de erros
- tomada de decisão técnica correta
- alinhamento com boas práticas de mercado

📌 Este aprendizado foi documentado como parte do portfólio para evidenciar maturidade técnica e pensamento crítico em projetos de dados.